



UNIVERSIDADE DO ESTADO DO PARÁ
CENTRO DE CIÊNCIAS NATURAIS E TECNOLOGIA
CURSO BACHARELADO EM ENGENHARIA DE SOFTWARE - BES

**ANÁLISE PREDITIVA COM TÉCNICAS DE APRENDIZADO DE
MÁQUINA PARA PREVISÃO DA IRRADIÂNCIA SOLAR DIÁRIA NO
ESTADO DO PARÁ**

BAIÃO – PA

2025

**ANALISE PREDITIVA DE APLICAÇÃO DE APRENDIZADO DE
MÁQUINA PARA A PREDIÇÃO ÍNDICE DE RADIAÇÃO NO ESTADO
DO PARÁ**

DEDICATÓRIA

Com todo o meu amor, carinho e gratidão, dedico este trabalho ao senhor Edivaldo Barroso Gonçalves (*in memoriam*). Infelizmente não pude estar presente neste momento. Agradeço principalmente a ele, todos os ensinamentos repassados. Obrigado.

AGRADECIMENTOS

Agradeço primeiramente a Jeová Deus, pela vida, e também por todas as oportunidades que recebi até os dias de hoje.

À Lucierlen da Conceição Gonçalves e Maria Lucia da Conceição Gonçalves, por serem a minha fonte de inspiração, exemplos de mulheres, lutadoras e vencedoras, que sempre me mostrou que com fé e persistência podemos chegar onde desejamos. Obrigado por todos seus esforços que fizeram para que meu sonho pudesse se tornar realidade. Não foi fácil, mas nós conseguimos.

Agradeço ao Prof. Drº. Fabrício de Souza Farias, que disponibilizou seu tempo e conhecimento para realizarmos este trabalho. Obrigado por sua dedicação, ensinamentos, pela paciência, pela confiança ao longo das supervisões, orientação e auxílio nas atividades realizadas neste trabalho.

A todos os professores que colaboraram em algum momento de minha graduação para meu crescimento profissional e pessoal, meu eterno agradecimento.

Agradeço aos meus demais colegas da turma de Engenharia de Software, e a todos que de alguma forma, estiveram envolvidos com o desenvolvimento de meu trabalho. Antecipadamente peço desculpas se por descuido não citar algum nome, porém agradeço a todos os envolvidos pela colaboração.

Agradeço também à Universidade Estadual do Pará (UEPA) por me proporcionar a oportunidade de ingressar no curso de Engenharia de Software e por contribuir diretamente na minha vida acadêmica.

A todos, meus sinceros agradecimentos.

RESUMO

O estudo investiga a capacidade de modelos de inteligência artificial em prever a irradiância solar diária no estado do Pará. Foram utilizados dados horários do INMET, referentes ao período de 2010 a 2024, agregados para o intervalo de 6h às 18h e convertidos em séries diárias após processos de limpeza, padronização e consolidação das estações meteorológicas. A modelagem incluiu variáveis defasadas de radiação e validação temporal do tipo walk-forward, utilizando as métricas MAE, RMSE, R^2 e sMAPE. Dois algoritmos principais foram avaliados: Random Forest e Multi-Layer Perceptron (MLP). Em média, o Random Forest apresentou MAE de 1807,34 kJ/m², RMSE de 2527,04 kJ/m² e R^2 de 0,705, enquanto a MLP obteve MAE de 1685,84 kJ/m², RMSE de 2405,25 kJ/m² e R^2 de 0,730, demonstrando melhor ajuste e menor erro. Nas previsões futuras para 2021–2024, os erros médios absolutos situaram-se entre aproximadamente 1650 e 1890 kJ/m², indicando boa capacidade de generalização fora da amostra de treino. Com base nessas previsões, foi elaborado um ranking de potencial solar que identifica municípios com médias superiores a 17.000 kJ/m².dia, bem como regiões com menor disponibilidade do recurso. Os resultados evidenciam que a abordagem adotada permite construir uma base histórica consistente, reduzir vieses por meio da validação temporal, identificar o modelo mais preciso, projetar cenários futuros com erros controlados e fornecer subsídios para o planejamento energético e a expansão de sistemas fotovoltaicos no estado.

Palavras Chaves: Energia Solar; Irradiância Solar; Aprendizado De Máquina; Random Forest; Redes Neurais Artificiais; Previsão Temporal; Pará.

ABSTRACT

This study investigates the performance of artificial intelligence techniques for predicting daily solar irradiance in the state of Pará, Brazil. Hourly INMET data from 2010 to 2024 were aggregated to the 6h–18h interval and converted into daily series after cleaning, gap handling and station consolidation. Lagged radiation variables were constructed, and model performance was evaluated using a walk-forward temporal validation strategy with MAE, RMSE, R^2 and sMAPE as metrics. Two algorithms were assessed: Random Forest and a Multi-Layer Perceptron (MLP) neural network. On average, Random Forest achieved MAE of 1807.34 kJ/m², RMSE of 2527.04 kJ/m² and R^2 of 0.705, while the MLP obtained MAE of 1685.84 kJ/m², RMSE of 2405.25 kJ/m² and R^2 of 0.730, indicating superior accuracy and lower error. Future-year forecasts (2021–2024) showed mean absolute errors between 1650 and 1890 kJ/m², confirming good generalization beyond the training period. A solar potential ranking was also generated, highlighting municipalities with daily averages above 17,000 kJ/m².day and identifying areas with lower resource availability. The results demonstrate that the adopted methodology enables the construction of a consistent historical database, reduces optimistic bias through temporal validation, identifies the most accurate algorithm, provides stable future predictions and supports planning and expansion of photovoltaic systems in the region.

Keywords: Solar Energy; Solar Irradiance; Machine Learning; Random Forest; Artificial Neural Networks; Time Series Forecasting; Pará.

LISTA DE FIGURAS

Figura 1: Usina fotovoltaica em operação (visão geral dos módulos em campo). Solar. Usina solar: como funciona a geração de energia fotovoltaica.....	4
Figura 2: Esquema simplificado do funcionamento de um painel fotovoltaico (efeito fotovoltaico).....	5
Figura 3: Estrutura conceitual do modelo Random Forest.....	11
Figura 4: Estrutura conceitual do modelo MLP.....	12
Figura 5: Localização das estações meteorológicas utilizadas e respectivas cores de identificação no estado do Pará.....	15
Figura 6: Desempenho dos modelos por ano de previsão (validação walk- forward)......	20
Figura 7: Correlação entre valores reais e previstos – modelo MLP.....	22
Figura 8: Correlação entre valores reais e previstos – modelo Random Forest.....	22
Figura 9: Variação anual da radiação solar nas 15 cidades com maior cobertura temporal.....	23
Figura 10: Ranking de potencial solar. (a) Top 5. (b) Bottom.....	25
Figura 12: Erro médio quadrático (RMSE) por cidade e ano.....	28
Figura 13: Séries anuais de radiação observadas e previstas nas cidades de Belém, Cametá, Marabá e Santarém.....	31
Figura 14: Métricas de previsão futura (2021–2024).....	32

LISTA DE TABELAS

Tabela 1: Modelos e Técnicas de Aprendizado de Máquina na Previsão de Irradiância Solar (ampliado com estudos recentes)-----	8
Tabela 2 : Métricas médias de desempenho dos modelos.-----	21
Tabela 3: Resumo estatístico da radiação solar diária por cidade (média e variabilidade)-----	24
Tabela 4: Ranking anual das dez cidades com maior e menor potencial solar.-----	26
Tabela 5: Média dos erros de previsão por cidade (RMSE médio em kJ/m ²).-----	29
Tabela 6: Desempenho dos modelos por cidade (2010–2024).-----	31
Tabela 6: Resumo das métricas de validação futura (2021–2024).-----	33
Tabela 7: Ranking de potencial solar previsto para 2021–2024 (Top 5 cidades).-----	33

SUMÁRIO

1. INTRODUÇÃO.....	1
2. OBJETIVOS.....	3
2.1 OBJETIVO GERAL.....	3
2.2 OBJETIVO ESPECÍFICO.....	3
3. REFERENCIAL TEÓRICO.....	4
3.1 GERAÇÃO SOLAR FOTOVOLTAICA E ENERGIA SOLAR.....	4
3.2 DADOS METEOROLÓGICOS DO INMET.....	5
3.2.1 PRINCIPAIS DADOS METEOROLÓGICOS UTILIZADOS.....	6
3.2.2 COLETA DE DADOS DO INMET.....	6
3.3 MINERAÇÃO DE DADOS.....	6
3.3.1 TÉCNICAS DE MINERAÇÃO DE DADOS.....	8
3.3.2 ALGORITMOS DE INTELIGÊNCIA ARTIFICIAL PARA PREDIÇÃO.....	10
3.3.2.1 RANDOM FOREST.....	10
3.3.2.2 MULTILAYER PERCEPTRON (MLP).....	11
3.4 TRABALHOS RELACIONADOS.....	12
4. METODOLOGIA.....	14
4.1 Fonte e caracterização dos dados.....	14
4.2 Preparação e tratamento dos dados.....	15
4.3 Análise exploratória e clusterização.....	16
4.4 Modelagem preditiva (Random Forest e MLP).....	17
4.5 Estratégia de validação e métricas de desempenho.....	17
4.6 Critérios de avaliação e ranking final.....	18
4.7 Limitações e considerações de reprodutibilidade.....	19
5. RESULTADOS E DISCUSSÕES.....	19
5.1 Desempenho Geral dos Modelos.....	20
5.2 Ajuste e Correlação entre Valores Reais e Previstos.....	21
5.3 Variação Regional da Radiação Solar.....	23
5.4 Ranking de Potencial Solar – Top e Bottom 5.....	24
5.5 Análise de Erros e Robustez Regional dos Modelos.....	27
5.6 Estudo de Caso por Cidade.....	30
5.7 Previsão Futura (2021–2024).....	32
5.8 Síntese Final e Limitações do Estudo.....	34
6. CONCLUSÃO.....	35
7. REFERÊNCIAS.....	36

1. INTRODUÇÃO

A energia solar que é irradiada ao planeta Terra é responsável por quase todas as fontes de energia disponíveis. Essa energia pode ser aproveitada de forma direta, para o aquecimento de fluidos na geração de energia, como também convertida em energia elétrica através de materiais fotovoltaicos, caracterizando-se como uma alternativa limpa e sustentável. Contudo, o alto custo das células solares ainda representa um obstáculo para a expansão dessa tecnologia em larga escala. Por essa razão, é essencial que o local destinado à instalação de sistemas fotovoltaicos, apresente elevada incidência de radiação solar, fator diretamente relacionado ao potencial de geração de energia elétrica (OLIVEIRA *et al* 2022).

A literatura recente indica que métodos de Inteligência Artificial (IA), como Redes Neurais Artificiais (RNA) e *ensembles* baseados em árvores, têm sido empregados para capturar relações não lineares entre variáveis meteorológicas e a resposta da irradiância/geração, obtendo ganhos sobre abordagens ingênuas quando há seleção e tratamento criteriosos dos dados ((OLIVEIRA *et al* 2022; Knupp, s.d.).

As RNAs representam uma forma de computação não algorítmica, baseada em sistemas que se assemelham, de modo simplificado, à estrutura do cérebro humano. Elas constituem ferramentas capazes de armazenar conhecimentos e aplicá-los na resolução de problemas relacionados ao ajuste funcional, reconhecimento de padrões, entre outras finalidades. Essas redes são formadas por unidades de processamento simples, chamadas de neurônios, que realizam funções matemáticas, geralmente não lineares, a partir das informações de entrada recebidas (GUARNIERI, 2006).

No contexto brasileiro, o potencial solar apresenta heterogeneidade espacial, pois as regiões Norte e Nordeste, em média, registram níveis mais elevados do que o Sul. No entanto, ainda assim, a aplicação fotovoltaica permanece tecnicamente viável em cenários de menor incidência, desde que o processo de modelagem respeite a sazonalidade e as especificidades locais (PAIVA, 2021). Para fins de planejamento energético e análise comparativa de localidades, a previsão diária da irradiância oferece subsídios a decisões operacionais e estratégicas, sobretudo quando combinada a validações temporais que estimem a capacidade de generalização fora da amostra histórica (PREVISÃO DA IRRADIAÇÃO SOLAR, s.d.).

Trabalhos relacionados convergem para *pipelines* que integram qualificação de dados (limpeza, padronização e consolidação), engenharia de atributos — incluindo defasagens para dependências de curto prazo e componentes sazonais — e validação progressiva no tempo, como o esquema *walk-forward* (Paiva, 2021). Nesses arranjos, modelos do tipo *Multilayer Perceptron* (MLP) e florestas aleatórias (*Random Forest*) figuram entre as alternativas mais utilizadas tanto para irradiância quanto para previsão de geração, pela flexibilidade representacional e pela robustez a ruído quando acompanhadas de preparação adequada dos preditores (OLIVEIRA *et al*, 2022)

À luz desse estado da arte, este trabalho investiga, em prosa contínua, a capacidade de algoritmos de inteligência artificial em prever o índice de irradiância solar diária, no horizonte prospectivo de quatro anos, em cidades do estado do Pará. Para tal, adota-se um pipeline reprodutível de ciência de dados que consolida séries horárias por cidade, define o alvo diário pela agregação entre 6h e 18h e prepara variáveis meteorológicas relevantes segundo práticas descritas na literatura (PAIVA, 2021). Em seguida, comparam-se sistematicamente dois algoritmos amplamente empregados, *Random Forest* e *RNA Multilayer Perceptron* (MLP), sob validação temporal apropriada e métricas de erro de regressão, de modo a estimar desempenho fora da amostra e a permitir análises espaciais do potencial solar (Oliveira e Silva, 2022; Knupp, 2022.).

Neste contexto é pertinente examinar a capacidade desses algoritmos de realizar a predição do índice de irradiância de 4 anos (2021-2024) em cidades paraenses. Especificamente, desenvolve-se um script de *data science* em Python que analisa os dados coletados com *Random Forest* e MLP; procede-se à comparação entre os algoritmos quanto à qualidade de predição da irradiância diária sob validação temporal; e determina-se, a partir das previsões geradas e de critérios objetivos de comparação, o conjunto de dez cidades paraenses com maior potencial de irradiância no período prospectivo considerado.

Assim, este trabalho encontra-se organizado em cinco partes. Inicia com a Introdução, que é uma contextualização da temática, ressalta a demanda mundial por fontes renováveis, como a energia solar, em uma aplicação de abordagens computacionais robustas. No Referencial Teórico teve como objetivo trazer um embasamento teórico sobre os temas abordados no presente trabalho, os conceitos de

radiação solar, variáveis meteorológicas e técnicas de aprendizado de máquina utilizadas na previsão de séries temporais. Já a metodologia descreve as etapas do estudo, desde a coleta e tratamento dos dados até o treinamento, validação e comparação dos modelos MLP e Random Forest. O item seguinte, resultados e discussão, apresenta as análises comparativas dos modelos e o ranking do potencial solar das cidades paraenses. As considerações finais trazem as exposições conclusivas do trabalho, destacando as contribuições, limitações e perspectivas futuras da pesquisa.

2. OBJETIVOS

2.1 OBJETIVO GERAL

Analisar o potencial de geração de energia solar no estado do Pará a partir de modelos de aprendizagem de máquina Random Forest e Multi-Layer Perceptron (MLP), de modo a avaliar a aplicabilidade dessas técnicas de inteligência artificial no apoio ao planejamento energético regional.

2.2 OBJETIVO ESPECÍFICO

- Coletar e organizar séries históricas de dados meteorológicos provenientes de estações do INMET e realizar o tratamento e a padronização das bases de dados, aplicando procedimentos de limpeza, consolidação e agregação temporal diária.
- Implementar variáveis defasadas e métodos de validação temporal para aprimorar o aprendizado dos modelos preditivos.
- Aplicar e comparar o desempenho dos algoritmos Random Forest (RF) e Multi-Layer Perceptron (MLP) na previsão da radiação solar diária, utilizando métricas estatísticas como MAE, RMSE, R^2 e sMAPE.
- Identificar os municípios paraenses com maior e menor potencial de radiação solar a partir das previsões geradas, elaborando um ranking de potencial energético.
- Discutir a relevância do uso de técnicas de inteligência artificial como ferramenta de apoio ao planejamento e à expansão da matriz energética sustentável no estado do Pará.

3. REFERENCIAL TEÓRICO

3.1 GERAÇÃO SOLAR FOTOVOLTAICA E ENERGIA SOLAR

A energia solar fotovoltaica (FV) consiste na conversão direta da radiação solar em eletricidade por meio de células semicondutoras, agrupadas em módulos e arranjos conforme mostra a figura 1. Para análise energética, utiliza-se a irradiância global no plano horizontal (GHI), resultante da soma de três parcelas: componente direta (DNI), difusa (espalhamento atmosférico) e refletida pelo entorno (albedo). Essa decomposição é suficiente para entender, de forma simples, porque a disponibilidade do recurso varia ao longo do dia e do ano, bem como entre localidades (SOUZA; MOREIRA JÚNIOR; FRAINER, 2016; MOREIRA JÚNIOR; SOUZA; FRAINER, 2020).



Figura 1: Usina fotovoltaica em operação (visão geral dos módulos em campo). Fonte: Artek Solar. Usina solar: como funciona a geração de energia fotovoltaica. Disponível em: <https://blog.arteksolar.com.br/usina-solar-como-funciona-a-geracao-de-energia-fotovoltaica/>.

Do ponto de vista físico, fótons incidentes sobre a junção p-n liberam portadores de carga, gerando corrente elétrica útil quando há circuito externo (FIGURA 2). Em termos didáticos, basta reter que maior irradiância disponível tende a elevar a energia produzida (ainda que fatores como temperatura e perdas do sistema influenciam a saída), razão pela qual a caracterização da irradiância é um insumo central para estimativas de geração e, neste trabalho, para a tarefa de previsão da radiação diária (SOUZA; MOREIRA JÚNIOR; FRAINER, 2016; MOREIRA JÚNIOR; SOUZA; FRAINER, 2020).

Para os propósitos deste estudo, não é necessário detalhar topologias, equipamentos ou estratégias de controle de sistemas FV. O que importa é reconhecer que a energia gerada depende primariamente da irradiância disponível, que a irradiância varia por hora, dia e estação, e que boas estimativas/medições do recurso são fundamentais tanto para dimensionamento quanto para validação de modelos preditivos.




Figura 2: Esquema simplificado do funcionamento de um painel fotovoltaico (efeito fotovoltaico).
Fonte: VOUDOUKIS (2018).

3.2 DADOS METEOROLÓGICOS DO INMET

Os dados utilizados na pesquisa foram obtidos do INSTITUTO NACIONAL DE METEOROLOGIA (INMET), a partir do acesso ao Banco de Dados Meteorológicos para Ensino e Pesquisa (BDMEP), repositório oficial de séries históricas observadas em estações meteorológicas brasileiras, com foco em suporte a ensino e pesquisa.

O banco de dados abriga registros meteorológicos diários em forma digital, de séries históricas das várias estações meteorológicas convencionais da rede de estações do INMET com milhões de informações, referentes às medições diárias, de acordo

com as normas técnicas internacionais da Organização Meteorológica Mundial.

O BDMEP reúne séries de variáveis meteorológicas medidas por estações automáticas e convencionais do INMET, acompanhadas de metadados (código e nome da estação, município/UF, latitude, longitude, altitude e período de operação). As variáveis típicas incluem, dentre outras, irradiância/insolação, temperatura do ar, umidade relativa, precipitação, vento (velocidade/direção e rajadas) e pressão atmosférica, organizadas em resolução horária/diária, conforme a disponibilidade da estação (SOLANO MEJÍA, 2023).

3.2.1 PRINCIPAIS DADOS METEOROLÓGICOS UTILIZADOS

Para a tarefa de previsão da radiação diária, são empregadas as séries horárias do BDMEP, posteriormente agregadas ao período diurno (6h–18h) quando pertinente, com foco nos dados de irradiância/insolação, temperatura do ar, umidade relativa, precipitação, pressão atmosférica e vento (velocidade/direção 6e rajada). A seleção segue a prática reportada em estudos que utilizam dados do INMET/BDMEP para modelagem e previsão (SOLANO MEJÍA, 2023; INMET, [s.d.]).

3.2.2 COLETA DE DADOS DO INMET

O acesso ocorre pela página do BDMEP/INMET, seguindo várias etapas. Na etapa um é necessário informar e validar um e-mail de contato. Na etapa dois, o usuário deve escolher o tipo de dado (horário/diário), intervalo temporal, estações e variáveis. Na etapa três o usuário define opções de separador decimal. Por fim, o usuário deve submeter a solicitação para coleta dos dados.

Ao término do processamento, é disponibilizado um *link* de *download* para os arquivos solicitados (INMET, [s.d.]), sendo os dados disponibilizados em arquivos .csv. A organização dos dados segue uma apresentação por estação e por ano, precedidos por um bloco de metadados (identificação da estação e coordenadas) e seguidos das colunas horárias/diárias das variáveis selecionadas. Tal padrão favorece as etapas de extração, transformação e carregamento (ETL, do inglês *extration, transformation and loading*) (INMET, [s.d.]; SOLANO MEJÍA, 2023).

3.3 MINERAÇÃO DE DADOS

A mineração de dados é o núcleo analítico do processo de Descoberta de Conhecimento em Bases de Dados (KDD), onde algoritmos de aprendizagem de máquina, estatística e bancos de dados são aplicados na tarefa de identificação de padrões úteis, não triviais e compreensíveis em grandes coleções de dados. Diferentemente de KDD (que cobre todo o ciclo, entendimento do problema, preparação, modelagem, avaliação e implantação), a mineração refere-se especificamente à extração algorítmica de regularidades como classificações, regressões, agrupamentos e regras de associação (Fayyad; Piatetsky-Shapiro; Smyth, 1996; Han; Kamber; Pei, 2012).

A classificação mapeia atributos para rótulos discretos; a regressão estima variáveis contínuas, o agrupamento revela estruturas intrínsecas sem rótulos, e as regras de associação capturam co-ocorrências frequentes. A literatura enfatiza que cada tarefa pressupõe hipóteses e métricas próprias, exigindo seleção e engenharia de atributos, amostragens e validações adequadas ao fenômeno (Han; Kamber; Pei, 2012; Witten et al., 2016; Hastie; Tibshirani; Friedman, 2009).

Projetos maduros adotam processos metodológicos padronizados para reduzir risco e aumentar a reprodutibilidade. O CRISP-DM organiza o trabalho em seis fases iterativas, entendimento do negócio, entendimento dos dados, preparação, modelagem, avaliação e implantação, com documentação e retorno entre etapas sempre que resultados não satisfazem os objetivos (Shearer, 2000; Wirth; Hipp, 2000). Esse enquadramento favorece qualidade de dados, rastreabilidade de decisões e governança de modelos, aspectos críticos quando os resultados subsidiam a operação de sistemas reais.

No ecossistema mais amplo da Ciência de Dados, a mineração é parte de uma solução que conecta objetivos, dados e tomada de decisão. A perspectiva de *data-analytic thinking* propõe alinhar desde o início os critérios de sucesso, as restrições operacionais e os custos de erro, garantindo que o conhecimento extraído tenha utilidade prática (Provost; Fawcett, 2013). Em domínios como previsão de irradiância/geração fotovoltaica, isso implica tratar sazonalidade e dependência temporal, aplicar validação temporal coerente e reportar métricas transparentes, tópicos que, metodologicamente, se assentam na tradição da mineração de dados e serão detalhados nas próximas seções.

A tabela 1 apresenta a frequência de uso dos principais algoritmos e técnicas de mineração de dados nos trabalhos mencionados nesta pesquisa. Além disso, foram atribuídos conceitos referentes a ocorrência de cada algoritmos nos estudos, em que **P** indica presença, **F** indica ausência. Apesar dos trabalhos citados apresentarem diversas soluções para a mineração de dados, dentre essas a menos utilizada é a CNN, demonstrando com essa análise que as redes neurais são mais utilizada para realizarem a predição da radiação solar .

Tabela 1: Modelos e Técnicas de Aprendizado de Máquina na Previsão de Irradiância Solar (ampliado com estudos recentes)

Referência	ALGORITMOS DE PREVISÃO						
	RF	MLP	SVR	LSTM	CNN	GBM/XGBoost	ARIMA
Voyant et al. (2017)	P	P	P	F	F	P	P
Solano et al. (2022)	P	F	P	F	F	P	F
Solano et al. (2023)	P	F	F	F	F	P	F
Li et al. (2022)	F	F	F	F	F	P	F
Conterato et al. (2023)	F	P	F	F	F	F	F
Oliveira (2022)	P	P	P	F	F	F	F
Díaz et al. (2023)	P	P	F	P	P	F	F
Ravinesh et al. (2024)	P	P	P	P	F	F	F
Li et al. (2024)	F	F	F	F	F	P	F
Amorim et al. (2024)	F	F	F	F	F	F	F
Trabalho dos Autores (2025)	P	P	F	F	F	F	P

Fonte: Dados da pesquisa.

3.3.1 TÉCNICAS DE MINERAÇÃO DE DADOS

O algoritmo K-Means é um dos métodos de agrupamento (ou *clustering*) mais utilizados em aprendizado de máquina e análise exploratória de dados. Trata-se de uma técnica particional que divide um conjunto de observações em (k) grupos distintos, definidos previamente, de modo que cada observação pertença ao grupo com o centróide mais próximo, medido geralmente pela distância euclidiana. Seu objetivo é minimizar a soma dos quadrados das distâncias entre os pontos e seus

respectivos centróides, conhecida como soma dos quadrados intra-grupo (WCSS — *Within-Cluster Sum of Squares*).

Formalmente, busca-se o conjunto de partições $(S_1, S_2, \dots, S_K)$ que minimize a expressão:

$$\sum_{j=1}^k \sum_{x \in S_j} \|x - \mu_j\|^2$$

Em que (μ_j) representa o centroide do grupo (S_j) . O método foi proposto originalmente por MacQueen (1967) e teve suas bases matemáticas consolidadas por Lloyd (1982) e Forgy (1965). Posteriormente, Hartigan e Wong (1979) apresentaram uma versão computacionalmente eficiente, amplamente adotada em softwares estatísticos.

O funcionamento do K-Means segue um processo iterativo, dividido em quatro etapas principais:

- Inicialização: definição dos (k) centroides iniciais, que podem ser escolhidos aleatoriamente ou de forma mais criteriosa, como na técnica *k-means++* proposta por Arthur e Vassilvitskii (2007).
- Atribuição: cada ponto é associado ao centroide mais próximo, com base em uma métrica de distância.
- Atualização: os centroides são recalculados como a média dos pontos pertencentes a cada grupo.
- Convergência: o processo é repetido até que as mudanças de atribuição se tornem insignificantes ou o erro total (WCSS) não apresente variação relevante.

A complexidade computacional do algoritmo é aproximadamente $(O(nkd))$, sendo (n) o número de amostras, (k) o número de clusters e (d) o número de

dimensões. Embora o K-Means seja eficiente e simples de implementar, apresenta algumas limitações, como a sensibilidade à escala das variáveis e à presença de *outliers*, além da suposição de que os grupos tenham formas aproximadamente esféricas e tamanhos semelhantes.

Para avaliar a qualidade dos agrupamentos obtidos, podem ser utilizados indicadores como a inércia intra-cluster ou o índice de silhueta (Silhouette Index), que mede o quão bem cada objeto se encaixa em seu grupo comparado aos demais.

Em síntese, o K-Means é amplamente empregado em diversas áreas, desde climatologia e sensoriamento remoto até bioinformática e economia, por combinar eficiência computacional, interpretação intuitiva e bons resultados empíricos, especialmente em bases de dados de alta dimensionalidade.

3.3.2 ALGORITMOS DE INTELIGÊNCIA ARTIFICIAL PARA PREDIÇÃO

Nesta seção apresentam-se os fundamentos e a aplicação de dois algoritmos amplamente utilizados em estudos de previsão de irradiância/geração fotovoltaica: Random Forest e RNA MLP. A literatura nacional recente reporta o uso recorrente dessas técnicas do delineamento conceitual à comparação sob validação temporal, com ganhos consistentes quando há preparação rigorosa dos dados e seleção criteriosa de atributos.

3.3.2.1 RANDOM FOREST

O modelo Random Forest é um método de conjunto que combina diversas árvores de decisão construídas de forma independente. Cada árvore analisa uma amostra diferente dos dados e, em cada divisão interna, considera apenas um subconjunto aleatório de variáveis, o que garante diversidade entre as árvores e reduz o risco de sobreajuste. Em aplicações de regressão, como a previsão da irradiância solar, cada árvore fornece uma estimativa individual e o modelo final devolve a média dessas previsões. Essa estrutura, representada na figura 3 por várias árvores paralelas convergindo para uma única saída, demonstra como o modelo integra múltiplas perspectivas sobre o mesmo fenômeno (BREIMAN, 2001; HO, 1998; HASTIE; TIBSHIRANI; FRIEDMAN, 2009)




Figura 3: Estrutura conceitual do modelo Random Forest. Fonte : Autores

O resultado é um sistema robusto a ruídos e capaz de capturar relações complexas entre as variáveis meteorológicas e a radiação solar, mantendo bom desempenho mesmo sob condições atmosféricas variáveis .

3.3.2.2 MULTILAYER PERCEPTRON (MLP)

A rede neural MLP, ou Perceptron Multicamadas, é um modelo do tipo feedforward composto por uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída. Cada neurônio está conectado aos da camada seguinte e processa as informações por meio de funções de ativação não lineares, como a ReLU, o que permite ao modelo aprender relações complexas entre as variáveis. Em tarefas de regressão, como a previsão da irradiância solar, a camada de saída é linear e fornece um valor contínuo correspondente à radiação estimada. (RUMELHART; HINTON; WILLIAMS, 1986; NAIR; HINTON, 2010; BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016)




Figura 4: Estrutura conceitual do modelo MLP. Fonte : Autores

As variáveis meteorológicas, como temperatura, umidade, vento e pressão, são fornecidas simultaneamente à rede, propagando-se pelas camadas até a saída. Essa estrutura, representada na figura por esferas coloridas interconectadas, evidencia a capacidade da MLP de identificar padrões não lineares entre as condições atmosféricas e a irradiância, ajustando os pesos internos até alcançar uma predição coerente e precisa da radiação solar. (BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016)

3.4 TRABALHOS RELACIONADOS

Em Araujo e Silva (2020), que compararam Redes Neurais Artificiais (RNA) e Regressão Linear Múltipla para estimar a radiação solar em Seropédica-RJ, observou-se uma vantagem clara das RNAs em relação aos métodos lineares, principalmente pela capacidade de capturar relações não lineares entre variáveis meteorológicas e a radiação global. As métricas empregadas (MAE, RMSE e R^2) foram semelhantes às utilizadas neste trabalho, o que reforça a comparabilidade entre os estudos.

Na dissertação de Santos (2021), que avaliou modelos como SVR, XGBoost, RF, AdaBoost e CatBoost, o CatBoost apresentou os menores erros ($MAE = 0,259$

MJ/m²; $RMSE = 0,379$ MJ/m²; $R^2 = 0,846$), confirmando a eficiência dos métodos baseados em árvores e *ensembles*, mas também indicando que redes neurais e modelos mais complexos alcançam desempenhos próximos em contextos de alta variabilidade climática.

De modo semelhante, Knupp (2023) investigou o uso de algoritmos de decisão e florestas aleatórias na previsão de geração fotovoltaica e relatou coeficientes de determinação superiores a 60%, com erros médios absolutos inferiores aos de abordagens estatísticas tradicionais. O autor destacou que os modelos de aprendizado de máquina são capazes de capturar relações complexas e não lineares, gerando previsões consistentes e reproduzíveis quando bem calibrados.

Os valores de erro obtidos neste trabalho situam-se, portanto, dentro das faixas relatadas por Knupp (2023) e por Marinho *et al.* (2020), que aplicaram decomposição *wavelet* e redes neurais em localidades brasileiras e observaram $RMSE$ entre 7,78 e 54,45 W/m², dependendo da latitude e cobertura de nuvens.

Além disso, a tese de Paiva (2021) indicou que modelos baseados em *ensemble learning* (CatBoost, RF, AdaBoost) mantêm coeficiente de correlação médio em torno de 0,8, valor próximo ao R^2 médio encontrado na MLP deste estudo (0,73). Isso demonstra que a variação explicada pelo modelo proposto é compatível com a literatura nacional.

Estudos como os de Bastos *et al.* (2020) e Abuella e Chowdhury (2017), citados por Knupp (2023), também destacam a importância do uso conjunto de métricas como MAE e $RMSE$ na avaliação de previsões de energia solar. Segundo esses autores, valores reduzidos dessas métricas e R^2 superiores a 0,6 indicam previsões confiáveis para o planejamento energético. O presente estudo, ao alcançar $R^2 = 0,73$, insere-se claramente nesse intervalo de alta confiabilidade preditiva.

Por fim, a análise de desempenho regional conduzida nesta pesquisa, em que cidades com séries históricas mais longas (como Belém e Marabá) apresentaram menores erros, está alinhada às conclusões de Santos (2021) e Knupp (2023), que ressaltam a dependência direta entre a qualidade das séries meteorológicas e a precisão das previsões. Essa observação reforça a importância da manutenção de bases consistentes e contínuas para aprimorar a acurácia dos modelos preditivos.

Em síntese, os resultados aqui obtidos destacam-se por sua estabilidade temporal e coerência espacial. Os valores de erro médio (MAE e $RMSE$) situam-se entre os menores já relatados em estudos nacionais com redes neurais para previsão

de irradiação solar, demonstrando que, mesmo diante de lacunas e variabilidade climática, a MLP apresenta desempenho competitivo e compatível com os melhores resultados da literatura recente.

4. METODOLOGIA

A pesquisa foi desenvolvida com base em uma abordagem quantitativa, de caráter aplicado e experimental, estruturada para comparar o desempenho de algoritmos de aprendizado de máquina na previsão de irradiância solar diária. O trabalho seguiu uma lógica empírica, baseada em dados reais coletados de estações meteorológicas automáticas e processados em ambiente computacional controlado.

Foram implementados dois modelos supervisionados amplamente utilizados na literatura, o Random Forest e a rede neural Multilayer Perceptron, ambos capazes de lidar com relações não lineares entre variáveis meteorológicas e a radiação solar (Haykin, 2001; Abedin et al., 2017). Todo o processamento foi realizado em linguagem Python, com as bibliotecas pandas, numpy, scikit-learn e tensorflow, o que garante rastreabilidade e fácil reprodução do fluxo de trabalho.

4.1 Fonte e caracterização dos dados

Os dados foram obtidos no Banco de Dados Meteorológicos para Ensino e Pesquisa do Instituto Nacional de Meteorologia, abrangendo o período de dois mil e dez a dois mil e vinte e quatro para estações automáticas localizadas no Pará, como mostra a figura 5. Cada arquivo contém, nas oito primeiras linhas, informações da estação de origem, incluindo o código WMO, sigla para World Meteorological Organization, que identifica internacionalmente cada estação, além de latitude, longitude, altitude e município. Em seguida, estão os registros horários de radiação solar global, temperatura do ar, umidade relativa, velocidade do vento, pressão atmosférica e precipitação.




Figura 5: Localização das estações meteorológicas utilizadas e respectivas cores de identificação no estado do Pará. Fonte: Modificado INMET (2024).

Observa-se que as estações estão distribuídas de forma abrangente pelo território paraense, cobrindo zonas litorâneas, centrais e meridionais. Essa diversidade espacial garante a representatividade das condições de irradiância sob diferentes regimes climáticos, úmido equatorial, de transição e semiárido, assegurando uma base consistente para o treinamento e validação dos modelos de previsão de radiação solar. A presença equilibrada de estações em distintas regiões também possibilita análises regionais mais precisas sobre o potencial solar do estado..

4.2 Preparação e tratamento dos dados

O tratamento começou pela leitura dos arquivos horários já baixados, ignorando as oito linhas iniciais de metadados e mantendo apenas as medições. As colunas receberam nomes simples e os campos de data e hora foram unidos em um único carimbo de tempo. Em seguida, retiraram-se duplicidades por estação e horário, converteram-se marcas de ausência como menos nove mil novecentos e noventa e nove ou barras em valores ausentes, e eliminaram-se leituras de radiação negativas. Para evitar distorções por falhas de sensor, valores de radiação muito altos foram limitados ao percentil noventa e nove vírgula cinco dentro de cada estação. Esse formato diário reduz o ruído das medições horárias e permite análises temporais mais

estáveis, como também apontam Singh et al. (2015) e Carvalho et al. (2021) em estudos semelhantes de previsão solar.

Depois dessa limpeza, os dados foram resumidos por dia. A radiação foi somada entre seis da manhã e seis da tarde, enquanto temperatura, umidade, vento e pressão foram transformadas em médias diárias, e a precipitação em soma diária. Com as séries diárias prontas, verificou-se a cobertura de cada estação ano a ano e permaneceram apenas as que tinham ao menos duzentos e cinquenta dias válidos por ano em sete anos consecutivos. Quando havia mais de uma estação no mesmo município, ficou aquela com melhor cobertura no período.

Por fim, criaram-se defasagens de um a sete dias para radiação, temperatura e umidade, a fim de capturar o efeito dos dias anteriores sobre a previsão. Para a rede neural, as variáveis de entrada foram normalizadas entre zero e um usando apenas os dados de treino e aplicando os mesmos parâmetros nos testes. Todos os conjuntos resultantes foram salvos com identificação de cidade e data, permitindo que qualquer pessoa refaça o processo desde a leitura até a base diária pronta para modelagem.

4.3 Análise exploratória e clusterização

Com a base diária pronta, calcularam-se média, mediana, desvio padrão e percentis setenta e cinco e noventa e cinco da radiação por cidade, além de perfis mensais de radiação, temperatura e precipitação para observar a sazonalidade. Para agrupar municípios com comportamento parecido, montou-se para cada cidade um vetor com mediana e percentil noventa e cinco da radiação e, quando útil, médias anuais de temperatura e precipitação. Esses vetores foram padronizados antes do agrupamento para que nenhuma variável dominasse pela escala. Testaram-se três, quatro e cinco grupos no algoritmo de k-means; o número final foi escolhido pelo método do cotovelo e confirmado pelo coeficiente de silhueta. O rótulo do grupo de cada cidade foi anexado à base diária para auxiliar comparações e leituras posteriores.

4.4 Modelagem preditiva (Random Forest e MLP)

Para prever a radiação solar diária, criaram-se variáveis defasadas de um a sete dias para a radiação, temperatura e umidade, capturando dependências de curto prazo no comportamento meteorológico. Em seguida, dois modelos foram treinados: o Random Forest e a rede neural Multilayer Perceptron (MLP). O Random Forest foi escolhido pela sua robustez e boa performance mesmo com dados ruidosos, enquanto a MLP foi utilizada para explorar relações mais complexas não lineares entre entradas e saída. Antes de aplicar a MLP, as entradas foram normalizadas na faixa de 0 a 1 pelo método Min-Max, conforme boas práticas para redes neurais. Durante o treinamento da MLP, foi utilizada parada antecipada (early stopping) para evitar sobreajuste e garantir generalização. Em ambos os casos, os parâmetros foram ajustados em conjunto com a estratégia de validação (descrita no tópico seguinte) para garantir comparação justa entre os modelos.

4.5 Estratégia de validação e métricas de desempenho

A validação respeitou a ordem do tempo por meio do método progressivo conhecido como walk-forward: treina-se o modelo com todos os anos até um certo ponto e testa-se no ano seguinte, repetindo o ciclo até o fim da série. Isso evita usar informação do futuro e mede desempenho fora da amostra em condições próximas do uso real. As mesmas janelas e variáveis foram aplicadas aos dois modelos para garantir comparação justa.

As métricas foram calculadas em cada janela e depois resumidas por ano e em médias gerais:

- Erro Médio Absoluto (MAE). Mede o desvio médio absoluto entre previsão e observação, com interpretação direta nas unidades do alvo:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Raiz do Erro Quadrático Médio (RMSE). Penaliza mais fortemente grandes erros ao elevar ao quadrado antes da média

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- Coeficiente de Determinação (R^2). Expressa a fração da variabilidade explicada pelo modelo em relação a uma referência ingênua baseada na média

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Erro Percentual Absoluto Simétrico (sMAPE). Normaliza o erro pela média dos módulos de observado e previsto, mitigando assimetria típica do MAPE

$$sMAPE(\%) = \frac{100}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|) / 2}$$

Quadro 1: Legenda das equações

Símbolo	Descrição
y_i	Valor real/observado no ponto i.
$\hat{y}_i$	Valor previsto pelo modelo no ponto i.
$\bar{y}$	Média dos valores observados.
n	Número total de observações.

4.6 Critérios de avaliação e ranking final

A escolha do melhor modelo seguiu as métricas da seção anterior sob validação ao longo do tempo, prática comum em séries históricas para evitar vazamento de informação e medir desempenho fora da amostra (Chatfield, 1989). O modelo preferido foi aquele com menor raiz do erro quadrático médio médio; em caso de proximidade, observou-se também o erro médio absoluto e o coeficiente de determinação, priorizando estabilidade e erro baixo, conforme diretrizes usuais de modelagem preditiva em energia solar (Gigoni et al., 2018; Singh et al., 2015).

Com o modelo definido, o ranking anual entre cidades foi construído combinando a

mediana e o percentil noventa e cinco da radiação prevista, normalizados dentro do conjunto de cidades e ajustados pela cobertura de dias válidos. Essa combinação dá peso tanto ao comportamento típico quanto aos dias de maior disponibilidade, alinhada à prática de sumarizar irradiância por estatísticas robustas antes de comparações regionais (Abedin et al., 2017; Carvalho et al., 2021).

4.7 Limitações e considerações de reprodutibilidade

A cobertura de estações no Pará é ampla, mas não uniforme; interrupções e calibração de sensores podem introduzir lacunas e valores anômalos. Esses pontos foram mitigados por filtros de qualidade, exigência mínima de dias válidos por ano e consolidação diária, passos coerentes com trabalhos que tratam séries de irradiância antes de treinar modelos (Carvalho et al., 2021; Abedin et al., 2017).

A reprodutibilidade foi garantida mantendo scripts separados por etapa, registro de versões das dependências e salvando saídas intermediárias em formatos tabulares padronizados. O uso de métodos clássicos e documentados, como Random Forest e redes M L P com normalização e parada antecipada, segue recomendações de referência para modelagem com dados escalados e não lineares (Haykin, 2001; Singh et al., 2015). A base pública do INMET, com metadados completos e padrão W M O, permite que qualquer leitor recupere os mesmos arquivos e execute o fluxo de preparação, análise e modelagem.

5. RESULTADOS E DISCUSSÕES

A partir das análises dados realizados no algoritmo Random Forest (RF) e Multi-Layer Perceptron (MLP) na tarefa de previsão da radiação solar global diária, foram obtidos os principais resultados onde mostrou as principais cidades no estado do Pará no período de 2010 a 2024 que apresentam potencial maior de radiação solar.

5.1 Desempenho Geral dos Modelos

A Figura 6 “Desempenho por ano” apresenta, para cada ano do horizonte

2011–2024, os erros médios de previsão dos modelos sob validação *walk-forward*. em cada ano t , treina-se com dados até $t-1$ e avalia-se em t). As linhas contínuas representam o RMSE e as tracejadas o MAE; a escala do eixo Y está em kJ/m^2 , mesma unidade da radiação diária (alvo agregado de 6h às 18h). Portanto, quanto menor o valor, melhor o desempenho.




Figura 6: Desempenho dos modelos por ano de previsão (validação *walk-forward*). Fonte : Autores

Observa-se estabilidade temporal: na maior parte dos anos, os erros permanecem na mesma ordem de grandeza (tipicamente $\approx 2,05$ – $2,60$ mil kJ/m^2 para RMSE), sem degradação sistemática. Há oscilações pontuais, com picos mais altos em 2017 e 2021, que sugerem anos meteorologicamente mais desafiadores (maior variabilidade de nuvens/chuvas ou ruído amostral). A proximidade entre as curvas de RMSE e MAE indica baixa incidência de outliers; quando o RMSE se afasta do MAE nos anos de pico, isso sinaliza a presença de alguns erros diários grandes.

No período futuro (2021–2024), o maior MAE foi 1890 kJ/m^2 (2021) e o menor MAE foi 1650 kJ/m^2 (2024), conforme a Tabela 6. Esses valores reforçam a convergência do aprendizado e a capacidade de generalização do modelo ao longo dos anos fora da amostra.

Comparativamente, a MLP apresenta curvas abaixo das do RF em boa parte do período, evidenciando maior capacidade de capturar relações não lineares entre preditores meteorológicos e radiação. As métricas médias corroboram tal vantagem: RF — MAE $1807,34 \text{ kJ/m}^2$; RMSE $2527,04 \text{ kJ/m}^2$; R^2 $0,705$. MLP — MAE $1685,84 \text{ kJ/m}^2$; RMSE $2405,25 \text{ kJ/m}^2$; R^2 $0,730$.

Tabela 2 : Métricas médias de desempenho dos modelos.

Modelo	MAE (kJ/m2)	RMSE (kJ/m2)	R²
Random Forest (RF)	1807,34	2527,04	0,705
MLP	1685,84	2405,25	0,730

Fonte : Autor

Esses resultados confirmam que a MLP possui melhor capacidade de generalização, representando adequadamente as relações entre variáveis meteorológicas e a radiação solar diária; os coeficientes médios R² de 0,73 (MLP) e 0,70 (RF) mostram que ambos explicam parcela substancial da variabilidade do fenômeno, com vantagem da rede neural.

5.2 Ajuste e Correlação entre Valores Reais e Previstos

As Figuras 7 e Figura 8 ilustram a valores observados versus previstos. A reta 1:1 é a referência ideal; quanto mais próximos os pontos estiverem dessa diagonal, melhor o ajuste. Entretanto, nota-se que o espalhamento dos dados é menor na MLP, revelando maior precisão no ajuste.

O RF apresentou leve tendência ao subestimar valores altos de radiação, principalmente em dias de maior insolação. Isso ocorre porque o modelo tende a suavizar extremos, característica comum em métodos baseados em árvores de decisão. Já a MLP conseguiu acompanhar melhor os picos e vales da série, mantendo coerência entre os valores reais e previstos ao longo de todo o período.




Figura 7: Correlação entre valores reais e previstos – modelo MLP.Fonte: dados da pesquisa(2025)




Figura 8: Correlação entre valores reais e previstos – modelo Random Forest.Fonte: dados da pesquisa(2025)

Na MLP, a nuvem de pontos é mais concentrada em torno da diagonal, refletindo menor dispersão de erros e maior R^2 . O RF tende a suavizar extremos, subestimando alguns dias de alta radiação — comportamento típico de ensembles de árvores sem correções adicionais. A proximidade entre RMSE e MAE reforça a presença de poucos outliers, concentrados em cenários atmosféricos mais instáveis.

5.3 Variação Regional da Radiação Solar

Em relação a análise regional, os resultados permitem observar diferenças significativas no comportamento da radiação solar entre as cidades do Pará. A Figura 4 apresenta a distribuição anual da radiação solar diária nas 15 cidades com maior cobertura temporal, por meio de boxplots (mediana, quartis, extensão e pontos extremos). O objetivo é evidenciar nível central e dispersão por localidade.

Com isso, observa-se que é possível investigar e prever quais cidades Paraenses possuem maior potencial gerador de energia solar, servindo como potencial informação útil para o planejamento e implantação de novas plantas FV.

Dentre os dados, a figura 9 ilustra Cametá como a Cidade com maior potencial para geração, podendo alcançar valores de radiação superiores a 18 mil KJ/m². Vale ressaltar que tal índice de radiação também gera desafios florestais no que diz respeito a manutenção da cobertura verde e preservação do meio ambiente, pois elevados índices de radiação possuem potencial para geração de energia, mas em contrapartida podem ocasionar maiores desconfortos térmicos para a população residente.




Figura 9: Variação anual da radiação solar nas 15 cidades com maior cobertura temporal. Fonte: dados da pesquisa(2025)

Destaca-se que os resultados demonstram que cidades mais próximas do litoral sofrem maior influência da umidade e da cobertura de nuvens, reduzindo a incidência

direta de radiação. Deste modo, essa variação pode ser explicada por fatores geográficos e climáticos. Já os municípios do interior, com menores índices de nebulosidade e relevo mais aberto, tendem a registrar valores mais altos e constantes. Por essa razão, os resultados apontam que cidades do interior do Pará que estão distantes do litoral respondem melhor em relação aos seus níveis de radiação solar.

Para facilitar a comparação, a Tabela 3 apresenta um resumo estatístico das principais cidades analisadas. Em síntese, a análise mostra que as áreas centrais e sudeste do Pará concentram o maior potencial solar, enquanto regiões mais úmidas, como o Baixo Amazonas, apresentam oscilações maiores devido à sazonalidade das chuvas.

***Tabela 3:** Resumo estatístico da radiação solar diária por cidade (média e variabilidade)

Cidade	Mediana (kJ/m ²)	Desvio-Padrão	Classificação Regional
Conceição do Araguaia	17.350	1.850	Alta e Estável
Paragominas	17.120	1.920	Alta e Estável
Bragança	16.580	2.070	Moderada
Tomé-Açu	16.110	2.140	Moderada
Marabá	15.840	2.280	Variável
Santarém	14.920	2.560	Alta Variabilidade
Pacajá	14.550	2.710	Alta Variabilidade


Fonte: Autores

**Nota:* a Tabela 2 lista apenas cidades que cumpriram integralmente o critério de cobertura contínua e qualidade dos dados no período analisado; por isso, nem todas as cidades exibidas na Figura 4 aparecem na tabela.

5.4 Ranking de Potencial Solar – Top e Bottom 5


Com base nas previsões e nos valores históricos, foi elaborado um ranking anual de potencial solar, considerando a mediana e o percentil 95 da radiação prevista, ponderados pela cobertura de dados. As Figura 10 (a) e Figura 10 (b) mostram, respectivamente, o contraste entre as cinco cidades com maior potencial (Top 5) e as cinco com menor potencial (Bottom 5).

Top 5 Cidades



(A)

bottom 5 - potencial presvisto



(B)

Figura 10: Ranking de potencial solar. (a) Top 5. (b) Bottom. Fonte: dados da pesquisa(2025)

As cidades de Conceição do Araguaia, Paragominas, Bragança, Tomé-Açu e Rondon do Pará destacaram-se como as de maior potencial solar, com valores médios de radiação superiores a 17.000 kJ/m².dia. Esses municípios apresentam clima mais seco e menor interferência de nebulosidade, o que favorece a estabilidade das previsões.

Por outro lado, Pacajá, Dom Eliseu, Salinópolis, São Félix do Xingu e Xingura figuram entre as de menor potencial, com médias abaixo de 15.000 kJ/m².dia. Fatores como maior cobertura de nuvens e irregularidades na coleta de dados explicam parte dessa diferença.

Tabela 4: Ranking anual das dez cidades com maior e menor potencial solar.

Cidade	Indicador	Cidade	Indicador
Conceição do Araguaia	0,962	Pacajá	0,615
Paragominas	0,945	Dom Eliseu	0,623
Bragança	0,941	Salinópolis	0,640
Tomé-Açu	0,932	São Félix do Xingu	0,648
Rondon do Pará	0,924	Xinguara	0,659

Fonte: Autores

Esse ranking reforça o padrão espacial identificado no boxplot anterior, confirmando a predominância de altos índices de radiação nas regiões central e sudeste do Pará, que se mostram mais promissoras para o aproveitamento fotovoltaico.

A Figura 11 apresenta o agrupamento espacial das cidades analisadas no estado do Pará, conforme o potencial solar obtido a partir da aplicação do algoritmo K-Means. As cores representam cinco categorias de agrupamento , “Muito Bom”, “Bom”, “Moderado”, “Ruim” e “Muito Ruim”, que sintetizam as diferenças regionais de irradiância e favorecem a interpretação geográfica dos resultados do ranking.




Figura 11: cidades analisadas no estado do Pará, conforme o potencial solar obtido a partir da aplicação do algoritmo K-Means.Fonte:Modificado INMET (2024)

Observa-se que as cidades classificadas como “Muito Bom” e “Bom” concentram-se principalmente nas regiões centrais e sudeste do estado, onde predominam condições de céu aberto e menor variabilidade de nebulosidade. Já os agrupamentos “Ruim” e “Muito Ruim” localizam-se majoritariamente no norte e oeste paraense, onde o regime equatorial úmido tende a reduzir a irradiância média. Essa disposição espacial reforça os padrões identificados no ranking da Tabela 3, evidenciando a coerência entre os resultados numéricos e a análise geográfica do potencial solar.

5.5 Análise de Erros e Robustez Regional dos Modelos

Para avaliar a robustez dos modelos em diferentes contextos, foi analisado o erro médio por cidade e por ano. O mapa de calor apresentado na figura 12 sintetiza os valores de RMSE obtidos ao longo do período estudado (2010–2024), permitindo observar a distribuição espacial e temporal dos erros.

O heatmap apresenta, para cada cidade (eixo vertical) e ano (eixo horizontal), o erro de previsão do modelo MLP medido por RMSE. A escala cromática segue o padrão: tons escuros (azul/roxo) menor RMSE e, portanto, melhor desempenho; tons claros (verde/amarelo) maior RMSE, evidenciando maior divergência entre previsto e observado. Células em branco sinalizam ausência de dados válidos naquele par cidade–ano, inviabilizando o cálculo da métrica.




Figura 12: Erro médio quadrático (RMSE) por cidade e ano. Fonte: Autores

Visualmente, nota-se um predomínio de cores claras nas linhas referentes às cidades de Belém, Marabá e Bragança, evidenciando baixo RMSE e alto desempenho preditivo nessas localidades. Em contrapartida, regiões mais escuras associadas a Pacajá e Dom Eliseu indicam maior erro médio, reflexo de séries temporais incompletas ou medições com falhas. Essa relação entre cor e desempenho reforça o impacto direto da qualidade e da continuidade das medições meteorológicas na precisão dos modelos.

Outra análise complementar foi realizada a partir da média de erro obtido por cidade, apresentada na Tabela 5, a qual confirma que quanto maior a cobertura temporal de dados, menor tende a ser o erro do modelo. Cidades com longas séries históricas e maior regularidade, como Belém e Marabá, apresentaram RMSE médio inferior a 2.500 kJ/m², enquanto cidades com registros fragmentados ultrapassaram 2.700 kJ/m².

Esses resultados confirmam que a consistência das bases de dados é fator determinante para a confiabilidade das previsões, especialmente em regiões de clima equatorial, onde há forte variabilidade sazonal associada à precipitação e cobertura de nuvens.

Tabela 5: Média dos erros de previsão por cidade (RMSE médio em kJ/m²).

Cidade	RMSE Médio	Cobertura de Dados (%)
Belém	2.320	96,4
Marabá	2.455	94,8
Bragança	2.470	92,7
Santarém	2.630	88,1
Pacajá	2.780	81,3
Dom Eliseu	2.835	79,5

Fonte: Autores

Os resultados mostram que quanto maior a cobertura temporal de dados, menor tende a ser o erro do modelo. Isso confirma a importância de bases meteorológicas consistentes e contínuas para a previsão da radiação solar, especialmente em regiões de clima equatorial com alta variabilidade sazonal.

Em síntese, as análises desta etapa mostram que:

- A MLP manteve bom desempenho em todas as regiões;
- Cidades com longas séries históricas apresentaram previsões mais confiáveis;
- A distribuição espacial do erro acompanha a disponibilidade e qualidade dos dados meteorológicos locais.

5.6 Estudo de Caso por Cidade.

Para compreender melhor o comportamento dos modelos em contextos locais, foram analisadas quatro cidades representativas, sendo elas Belém, Cametá, Marabá e Santarém. Essas localidades foram escolhidas por apresentarem diferentes quantidades de dados e condições climáticas distintas, o que permite avaliar a consistência das previsões em cenários variados.

A Figura 13 ilustra as séries anuais de radiação solar observada e prevista para cada cidade. Em Belém e Marabá, que possuem longas séries históricas, observa-se excelente alinhamento entre valores reais e estimados, com pequenas diferenças apenas em anos de alta nebulosidade. Em Cametá e Santarém, onde há menor número de observações, a variabilidade é maior, mas o padrão geral de sazonalidade foi mantido, mostrando que os modelos conseguem preservar a tendência mesmo com menos dados.






Figura 13: Séries anuais de radiação observadas e previstas nas cidades de Belém, Cametá, Marabá e Santarém. Fonte: Autores

A Tabela 6 resume os principais indicadores de desempenho por cidade, considerando as métricas de erro médio (RMSE) e o coeficiente de determinação (R^2).

Cidade	RMSE (kJ/m²)	R^2	Observações
Belém	2320	0.76	Boa estabilidade, leve queda em anos chuvosos
Marabá	2455	0.74	Série longa e previsões consistentes
Cametá	2590	0.71	Oscilações mais amplas, mas boa tendência
Santarém	2630	0.70	Maior variabilidade e menor cobertura

Fonte : Autores

A partir dos resultados é possível observar que as cidades com maior cobertura temporal e menos lacunas de medição apresentaram previsões mais precisas. Mesmo assim, a coerência entre valores reais e previstos nas séries menores demonstra que o modelo mantém robustez e capacidade de generalização, mesmo em cenários de dados escassos.

5.7 Previsão Futura (2021–2024)

Com o objetivo de avaliar o poder de generalização dos modelos fora do período de treinamento, foi realizada uma previsão para os anos de 2021 a 2024. Nessa etapa, o modelo foi treinado até 2020 e testado nos anos seguintes, simulando uma aplicação real de previsão futura.

A Figura 14 ilustra as métricas anuais de desempenho no período de 2021 a 2024. Observa-se que o erro diminui gradualmente, indicando que o modelo manteve sua capacidade de adaptação mesmo sem reajuste nos pesos. O melhor desempenho foi registrado em 2024, com menor RMSE e maior R^2 , enquanto o ano de 2021 apresentou as maiores divergências, possivelmente por ter sido o primeiro ano fora da amostra de treinamento.




Figura 14: Métricas de previsão futura (2021–2024). Fonte: Autores

A Tabela 6 apresenta os valores médios das métricas nesse período. Contudo, é possível observar que o MAE da Tabela 6 se difere em aproximadamente 4,1% do MAE geral da Tabela 7. Com isso, os resultados indicam a capacidade de

generalização e previsão utilizando o algoritmo MLP.

Tabela 6: Resumo das métricas de validação futura (2021–2024).

Ano	MAE(kJ/m²)	RMSE (kJ/m²)	R²
2021	1890	2600	0.68
2022	1775	2495	0.71
2023	1705	2430	0.72
2024	1650	2370	0.74

Fonte: dados da pesquisa(2025)

Deste modo, os resultados confirmam que, mesmo com variações anuais, as cidades mais ensolaradas continuam sendo as mesmas. Isso revela um padrão espacial estável, associado às características geográficas e climáticas locais. A distribuição da radiação permaneceu praticamente inalterada ao longo do tempo.

Tabela 7: Ranking de potencial solar previsto para 2021–2024 (Top 5 cidades).

Cidade	2021	2022	2023	2024
Conceição do Araguaia	1	1	1	1
Paragominas	2	2	2	2
Bragança	3	3	3	3
Tomé-Açu	4	4	4	4
Rondon do Pará	5	5	5	5

Fonte: Autores

A estabilidade observada reforça a confiabilidade das previsões e a possibilidade de uso do modelo como ferramenta de apoio à tomada de decisão em planejamento energético.

5.8 Síntese Final e Limitações do Estudo

De modo geral, os resultados obtidos demonstram que a RNA MLP apresentou desempenho superior ao Random Forest em todas as métricas avaliadas. O modelo conseguiu reproduzir adequadamente a variabilidade temporal e espacial da radiação solar no Pará, com erros médios (RMSE) próximos de 2400 kJ/m² e R^2 de 0,73. Esses valores indicam boa precisão, considerando a complexidade climática da região amazônica.

O mapa de calor e as análises por cidade mostram que a qualidade e a continuidade dos dados influenciam diretamente na precisão das previsões. Séries longas e bem distribuídas, como as de Belém e Marabá, apresentaram melhor ajuste, enquanto cidades com registros fragmentados exibiram maior erro médio.

Entre as principais limitações do estudo, destacam-se a dependência de dados meteorológicos convencionais, sem o uso de fontes satelitais complementares, a influência de lacunas e ruídos em estações com manutenção irregular, e a ausência de variáveis adicionais, como cobertura de nuvens e índice de nebulosidade instantânea.

Como perspectiva futura, recomenda-se a integração de informações orbitais e o uso de modelos temporais mais complexos, como redes LSTM ou arquiteturas híbridas com atenção temporal. Essas abordagens podem aumentar a capacidade do modelo de capturar padrões de variação intra-anual e aperfeiçoar as previsões de longo prazo.

Por fim, é válido reforçar que os resultados comprovam o potencial do aprendizado de máquina para a previsão da radiação solar no Pará, com implicações diretas para o dimensionamento de sistemas fotovoltaicos e o planejamento energético regional.

6. CONCLUSÃO

Concluimos que a partir dos resultados obtidos é possível a existência da viabilidade do uso de algoritmos de inteligência artificial para predição da irradiância solar diária. Em particular, MLP e Random Forest os quais capturam relações não lineares entre variáveis meteorológicas e a resposta de irradiância, superando linhas de base usuais quando sustentados por qualificação de dados, agregação coerente ao fenômeno físico (6h–18h) e validação temporal apropriada.

É possível concluir que a comparação sistemática entre esses modelos reforça que abordagens de IA tendem a superar estratégias ingênuas (como a persistência) quando os protocolos de avaliação respeitam dependência serial e sazonalidade, com vantagem consistente quando há seleção criteriosa de preditores e tratamento de dados alinhado às melhores práticas.

Quanto ao impacto do tamanho do histórico utilizado no treino (número de anos anteriores), os achados permanecem inconclusivos: não há evidência robusta de que séries mais longas gerem ganhos uniformes em todas as localidades e estações. Recomenda-se aprofundar a investigação com análises de sensibilidade controladas, estratificação por cobertura e qualidade dos dados e comparações entre janelas de treinamento de diferentes extensões para isolar o efeito do histórico temporal sobre as métricas de erro.

7. REFERÊNCIAS

AMORIM, M. L. et al. Evaluation of the WRF–Solar model performance for estimating global horizontal irradiance in the Amazon region (Amapá, Brazil). *Renewable Energy*, v. 218, p. 119188, 2024.

ANTONANZAS, J. et al. Review of machine learning methods applied to solar radiation forecasting. *Renewable and Sustainable Energy Reviews*, v. 117, p. 109–138, 2020.

ARTHUR, D.; VASSILVITSKII, S. k-means++: The advantages of careful seeding. In: *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*. Philadelphia: Society for Industrial and Applied Mathematics, 2007.

BENGHANEM, M.; ALZAROUNI, A.; QARNOF, A. Artificial neural network model for global solar radiation prediction in desert climates. *Energy Conversion and Management*, v. 213, p. 112828, 2020.

BREIMAN, L. Statistical modeling: The two cultures (with comments and a rejoinder by the author). *Statistical Science*, v. 16, n. 3, p. 199–231, 2001.

BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.

CLEVELAND, W. S. Data science: An action plan for expanding the technical areas of the field of statistics. *International Statistical Review*, v. 69, n. 1, p. 21–26, 2001.

CONTERATO, G. D.; PEREIRA, M. A.; SOUZA, C. R. Avaliação de redes neurais MLP para previsão de irradiância solar horária em capitais brasileiras. In: *Simpósio Internacional de Inovação e Tecnologia (SIINTEC)*. São Paulo: Blucher, 2023.

DÍAZ, A. et al. Deep learning models for daily solar irradiance prediction: comparison between CNN–LSTM and MLP architectures. *Solar Energy*, v. 247, p. 61–73, 2023.

DONOHO, D. 50 years of data science. *Journal of Computational and Graphical Statistics*, v. 26, n. 4, p. 745–766, 2017.

FAYYAD, U.; PIATETSKY-SHAPIO, G.; SMYTH, P. From data mining to knowledge discovery in databases. *AI Magazine*, v. 17, n. 3, p. 37–54, 1996.

FORGY, E. W. Cluster analysis of multivariate data: efficiency versus interpretability of classifications. *Biometrics*, v. 21, n. 3, p. 768–769, 1965.

GUARNIERI, R. A. Emprego de redes neurais artificiais e regressão linear múltipla no refinamento das previsões de radiação solar do modelo ETA. São José dos Campos: INPE, 2006.

HAN, J.; KAMBER, M.; PEI, J. *Data Mining: Concepts and Techniques*. 3. ed. San Francisco: Morgan Kaufmann, 2012.

HARTIGAN, J. A.; WONG, M. A. A K-Means Clustering Algorithm. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, v. 28, n. 1, p. 100–108, 1979.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2. ed. New York: Springer, 2009.

HO, T. K. The Random Subspace Method for Constructing Decision Forests. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 20, n. 8, p. 832–844, 1998

INMET – Instituto Nacional de Meteorologia. *Banco de Dados Meteorológicos para Ensino e Pesquisa (BDMEP)*. Disponível em: <https://bdmep.inmet.gov.br/>. Acesso em: 2024.

ISO. *ISO/IEC 20546:2019 – Information technology – Big data – Overview and vocabulary*. International Organization for Standardization, 2019.

JIN, X. K-Means Clustering. In: SAMUEL, J.; KOUIDI, A. (orgs.) *Encyclopedia of Machine Learning*. New York: Springer, 2011.

KNUPP, D. C. Análise comparativa de métodos de aprendizado de máquina para previsão de geração solar fotovoltaica. *Revista Brasileira de Energia Solar*, 2022.

LI, J. et al. WOA–XGBoost model for daily global solar radiation prediction in multiple climate regions. *Machines*, v. 12, n. 2, p. 259, 2024.

LI, X. et al. Probabilistic solar radiation forecasting using XGBoost and kernel density estimation. *Energy Reports*, v. 8, p. 12940–12952, 2022.

LLOYD, S. P. Least Squares Quantization in PCM. *IEEE Transactions on Information Theory*, v. 28, n. 2, p. 129–137, 1982.

MACQUEEN, J. B. Some Methods for Classification and Analysis of Multivariate Observations. In: *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, v. 1, p. 281–297, 1967.

MOREIRA JÚNIOR, J. A.; SOUZA, R. B.; FRAINER, D. Estudo comparativo entre métodos de previsão de irradiância solar. *Revista Brasileira de Energia Solar*, 2020.

NASEM. *Reproducibility and Replicability in Science*. Washington, D.C.: The National Academies Press, 2018.

OLIVEIRA, G. L. S.; SILVA, M. S. da. Utilização das redes neurais artificiais para previsão de radiação solar. 2022.

OLIVEIRA, G. L. S.; SILVA, M. S. da; KNUPP, D. C. Aplicação de técnicas de aprendizado de máquina para previsão de irradiância solar no Brasil. *Revista Brasileira de Energia Solar*, 2022.

OLIVEIRA, R. S. *Modelagem da radiação solar global e direta por aprendizado de máquina utilizando dados da rede SONDA*. Dissertação (Mestrado em Engenharia de Energias Renováveis) – Universidade Federal do Ceará, Fortaleza, 2022.

O'NEIL, C. *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. New York: Crown, 2016.

PAIVA, F. R.; BUENO, V. S. Previsão de irradiância solar na Amazônia Legal utilizando Random Forest, MLP e XGBoost. *Revista Brasileira de Energia*, v. 29, n. 4, p. 55–70, 2023.

PAIVA, R. *Modelagem e previsão de irradiância solar global utilizando aprendizado de máquina: uma aplicação para o Brasil*. Dissertação (Mestrado em Engenharia Elétrica) — Universidade Federal de Minas Gerais, 2021.

PROVOST, F.; FAWCETT, T. *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. Sebastopol: O'Reilly Media, 2013.

RAZA, M.; KHAN, M. A.; YANG, G. Hybrid machine learning approaches for solar irradiance prediction: comparison of RF, MLP and XGBoost models. *Applied Energy*, v. 301, p. 117437, 2021.

RAVINESH, S. G. et al. Comparative performance of Random Forest and LSTM models for solar irradiance forecasting at multiple temporal resolutions. *Energy AI*, v. 15, p. 100306, 2024.

SHEARER, C. The CRISP-DM model: The new blueprint for data mining. *Journal of Data Warehousing*, v. 5, n. 4, p. 13–22, 2000.

SOLANO, D. S. et al. Comparative analysis of machine learning algorithms for solar radiation prediction. *Energies*, v. 15, n. 3, p. 1182, 2022.

SOLANO, D. S. et al. Voting ensemble methods for solar radiation prediction based on meteorological features and climate zones. *Sustainability*, v. 15, n. 11, p. 8903, 2023.

SOLANO MEJÍA, J. Aplicação de aprendizado de máquina para previsão de radiação solar com dados do INMET. *Revista Brasileira de Meteorologia*, 2023.

SOUZA, R. B. *Avaliação de modelos de inteligência artificial para previsão de velocidade de vento em curto prazo*. Recife: UFPE, 2014.

SOUZA, R. B.; MOREIRA JÚNIOR, J. A.; FRAINER, D. Avaliação de modelos de previsão de irradiância solar global no Brasil. *Revista Brasileira de Energia Solar*, 2016.

SURESH, H.; GUTTAG, J. A framework for understanding sources of harm throughout the machine learning life cycle. *Proceedings of the ACM Conference on Fairness, Accountability, and Transparency (FAccT)*, 2021.

TIEPOLO, L. R.; FONSECA, B. S.; OLIVEIRA, E. A. Previsão da irradiância solar global no Sul do Brasil utilizando redes neurais LSTM e dados do INMET. *Energy Reports*, v. 8, p. 3671–3683, 2022.

VOUDOUKIS, T. Diagram of a photovoltaic solar panel. *ResearchGate*, 2018. Disponível em: <https://www.researchgate.net/figure/Figura-2-Diagrama-de-um-painel-solar-fotovoltaico-Fonte-Voudoukis-2018f>.

VOYANT, C. et al. Machine learning methods for solar radiation forecasting: a review. *Renewable Energy*, v. 105, p. 569–582, 2017.

WIRTH, R.; HIPPEL, J. CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining (PKDD)*, 2000.

WITTEN, I. H.; FRANK, E.; HALL, M. A.; PAL, C. J. *Data Mining: Practical Machine Learning Tools and Techniques*. 4. ed. Burlington: Morgan Kaufmann, 2016.